Estimación de riesgo de grooming a partir de la edad aparente de la voz

Reporte técnico del proyecto

Octubre de 2026

Resumen

El grooming en línea —el proceso por el que una persona adulta se gana la confianza de una persona menor de edad con fines sexuales— crece año con año y se desplaza a espacios con voz, como los videojuegos en línea y las llamadas. Este proyecto construye un sistema que, usando *solo la voz*, estima si en una conversación participan una persona menor de edad y una adulta, sin transcribir ni analizar lo que se dice. El sistema separa a los hablantes, estima para cada uno la probabilidad de ser niño, adolescente o adulto, y combina esas probabilidades en un puntaje de riesgo. Se compararon seis modelos de aprendizaje de máquina sobre 23 893 fragmentos de audio (27,7 horas). El mejor, basado en vectores de hablante ECAPA-TDNN y una máquina de vectores de soporte, alcanza un F1-macro de 0,817, detecta el 98,7 % de los fragmentos infantiles y el 60,4 % de los adolescentes. El resultado es una **alerta para priorizar revisión humana**, nunca una prueba de que exista grooming.

Principio rector: es una alerta, no un decisor. Que un menor hable con un adulto no es grooming: padres, docentes, médicos y entrenadores producen exactamente la misma señal. Un riesgo de 90 % significa "el modelo está bastante seguro de que hay un niño y un adulto distintos", no "90 % de probabilidad de grooming". Ninguna acción con consecuencias debe tomarse solo con este puntaje.

Índice

1. Contexto: el grooming en línea **3**
1.1. La magnitud del problema . . . 3
1.2. Por qué la voz . . . 3

2. Objetivo y alcance **3**

3. Por qué el sistema no analiza lo que se dice **4**

4. Datos **4**

5. Metodología **5**
5.1. Flujo del sistema . . . 5
5.2. Preprocesamiento y aumentación de datos . . . 6
5.3. Representaciones de la voz . . . 6
5.4. Modelos y por qué los usamos . . . 7
5.5. Cómo funciona cada modelo . . . 7
5.6. Independencia del idioma: sustento y matices . . . 8
5.7. Protocolo de entrenamiento . . . 9
5.8. Puntaje de riesgo . . . 9

6. Resultados **11**
6.1. Comparativa de modelos 11
6.2. Eficiencia 12
6.3. Auditoría de sesgo por canal 12
6.4. Conversaciones simuladas 12

7. El sistema en funcionamiento **13**

8. Pruebas realizadas **13**

9. Limitaciones y trabajo futuro **14**

10. Consideraciones éticas **14**

11. Conclusiones **14**

1. Contexto: el grooming en línea

El *grooming* en línea es el proceso mediante el cual una persona adulta establece contacto y confianza con una persona menor de edad, a través de medios digitales, para facilitar un abuso sexual [1]. Suele avanzar por etapas —contacto, construcción de confianza, aislamiento, sexualización— y aprovecha plataformas donde los menores pasan tiempo: redes sociales, mensajería y videojuegos en línea.

1.1. La magnitud del problema

Tabla 1: Indicadores recientes sobre explotación y grooming en línea.

Fuente	Dato	Periodo
NCMEC / Thorn (EE. UU.)	Los reportes de *incitación en línea* (un adulto que se comunica con un menor con fines sexuales) subieron 192 %, a más de 546 000 [3]; en 2023 habían sido unos 186 800 [2].	2024
NCMEC	Casi 100 reportes *al día* de extorsión sexual con fines económicos; al menos 36 adolescentes varones se han quitado la vida tras ser víctimas desde 2021 [2].	2024
NSPCC (Reino Unido)	7 263 delitos de comunicación sexual con un menor registrados por la policía, casi el doble que en 2017/18; el 40 % de los casos con plataforma identificada ocurrió en Snapchat [4].	2024/25
WeProtect Global Alliance	En plataformas de videojuegos, una conversación puede volverse grooming de alto riesgo en 45 minutos en promedio, y en tan solo 19 segundos [5].	2023
WeProtect Global Alliance	Aumento de 87 % en reportes de material de abuso sexual infantil desde 2019 [5].	2019–2023
INEGI, MOCIBA (México)	21,0 % de las personas usuarias de internet de 12 años o más —18,9 millones— vivió ciberacoso; la forma más común fue el contacto mediante identidades falsas, y los medios principales, WhatsApp (39,8 %) y Facebook (39,7 %) [6].	2024

Dos matices al leer estas cifras. Parte del salto de 2024 en Estados Unidos se debe a la *REPORT Act*, que volvió obligatorio reportar la incitación en línea [3]: refleja más casos visibles, no necesariamente más casos. Y la cifra de México mide ciberacoso en general, del cual el grooming es una forma particular.

1.2. Por qué la voz

La mayoría de las herramientas de detección automática analizan texto de chats, como en la competencia PAN 2012 de identificación de depredadores sexuales [8]. Pero el contacto ocurre cada vez más por voz: chats de voz en videojuegos, notas de voz y llamadas. La voz tiene además una propiedad útil: **delata la edad aproximada del hablante**, porque los niños tienen cuerdas vocales y tracto vocal más cortos, lo que eleva el tono y las resonancias de la voz. Este proyecto aprovecha esa señal para detectar la *condición previa* del grooming —que un menor y un adulto estén hablando—, sin necesidad de escuchar qué dicen.

2. Objetivo y alcance

Objetivo. Dado un audio de una conversación, estimar la probabilidad de que en él participen una persona menor de edad y una persona adulta distintas, para priorizar qué conversaciones debe revisar una persona especializada.

Clases de edad.

- **Niño**: 12 años o menos.
- **Adolescente**: de 13 a 17 años.
- **Adulto**: 18 años o más.

Fuera del alcance. El sistema no analiza el contenido de la conversación, no identifica a las personas y no decide si hay un delito. Tampoco toma acciones automáticas (bloqueos, denuncias).

3. Por qué el sistema no analiza lo que se dice

Una decisión central del diseño es que el sistema **no transcribe ni interpreta el contenido** de la conversación; solo mide rasgos acústicos de la voz relacionados con la edad. Las razones:

1. **Privacidad y confidencialidad de las comunicaciones.** Analizar el contenido de conversaciones privadas es una de las intervenciones más intrusivas posibles. Las autoridades europeas de protección de datos (EDPB y EDPS) recomendaron eliminar la detección de grooming de la propuesta de reglamento europeo contra el abuso sexual infantil, por su carácter intrusivo, probabilístico y sus tasas de error, y fueron especialmente críticas con el escaneo de comunicaciones de *audio*, que exigiría interceptación continua y en vivo [7]. Nuestro enfoque evita ese escaneo de contenido por diseño.
2. **Minimización de datos.** De cada hablante solo se conservan tres probabilidades (niño, adolescente, adulto). No se generan transcripciones, no se guardan audios ni se identifica a nadie: el audio se procesa en memoria y se descarta al terminar.
3. **Proporcionalidad.** Una alerta basada en la edad aparente permite priorizar casos sin exponer lo que dijeron menores y adultos inocentes, que serán la mayoría de las alertas.
4. **Independencia del idioma.** Las pistas de edad (tono y resonancias de la voz) dependen sobre todo de la anatomía, no del idioma ni del vocabulario; la sección 5.6 reúne la evidencia y sus matices. Un análisis de contenido, en cambio, necesitaría modelos por idioma, jerga y contexto cultural.
5. **Menor superficie de riesgo.** Un sistema que nunca produce texto de las conversaciones no puede filtrarlo, ni usarse para vigilar lo que la gente dice.

El costo de esta decisión, que debe decirse con claridad: el sistema no distingue una conversación legítima de una abusiva. Detecta la combinación "menor + adulto", no la intención. Por eso su salida es una alerta para revisión humana y nunca un veredicto.

4. Datos

No existe un corpus público grande que tenga, en un mismo canal de grabación, voces de niños, adolescentes y adultos con edad etiquetada. Se unieron dos corpus públicos en inglés:

Tabla 2: Corpus utilizados.

Corpus	Contenido	Edad	Clase
ENNI (habla infantil sintetizada) [9, 10]	9 997 fragmentos de 349 niños de 4 a 10 años, generados a partir de narraciones reales; incluye niños con desarrollo típico y con trastorno del lenguaje	Exacta	Niño
Common Voice, década *teens* [11]	Voluntarios grabados con micrófonos caseros	"Menor de 19"	Adolescente
Common Voice, década *twenties* y mayores	143 170 fragmentos con edad declarada en total	Por década	Adulto

Construcción del conjunto unido.

1. Se descartaron los fragmentos marcados como inválidos en Common Voice, los de menos de 1 s o más de 15 s y los fragmentos mudos.
2. Como esta versión de Common Voice no identifica a los hablantes, se agruparon sus fragmentos en *pseudo-hablantes* por década, género y acento. Una persona siempre declara los mismos datos, así que nunca queda repartida entre entrenamiento y prueba.
3. Se limitaron los fragmentos por pseudo-hablante y se submuestreó a los adultos para equilibrar las clases.
4. Todo se convirtió a audio mono de 16 kHz.

El resultado: **23 893 fragmentos y 27,7 horas**: 9 970 de niños (11,6 h), 3 960 de adolescentes (4,1 h) y 9 963 de adultos (12,0 h).

Partición por hablante. Ningún hablante aparece en dos particiones; si apareciera, el modelo memorizaría voces y las métricas saldrían infladas. Se reparten hablantes completos en proporción aproximada 70/15/15 (figura 1).

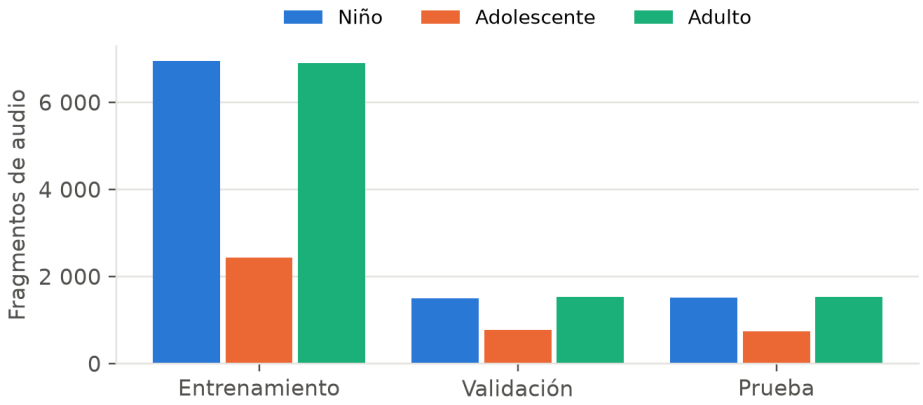


Figura 1: Fragmentos por clase en cada partición. En prueba hay 53 niños, 4 grupos de adolescentes y 24 grupos de adultos.

5. Metodología

5.1. Flujo del sistema

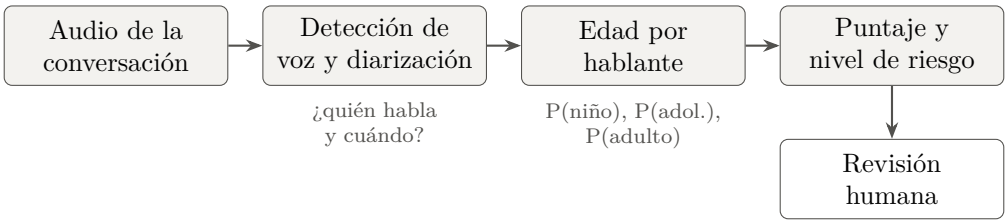


Figura 2: Flujo de punta a punta. El contenido de lo que se dice nunca se analiza.

1. **Carga y normalización:** audio mono a 16 kHz con el volumen igualado, para que el modelo no aprenda que una fuente está grabada más fuerte que otra.
2. **Detección de actividad de voz** por energía, para quitar los silencios.

3. **Diarización:** el audio se corta en ventanas de 1,5 s, a cada ventana se le calcula un vector de hablante (ECAPA-TDNN) y las ventanas se agrupan por similitud. Cada grupo es un hablante.
4. **Estimación de edad:** el audio de cada hablante se divide en trozos de hasta 6 s, el modelo estima las probabilidades de cada trozo y se promedian según su duración.
5. **Riesgo:** se combinan las probabilidades de todos los pares de hablantes (sección 5.8).

5.2. Preprocesamiento y aumentación de datos

Antes de extraer características, cada fragmento se recorta a sus primeros 8 s, se normaliza y se le quitan los silencios; los que quedan con menos de 1 s de voz se descartan. Para el entrenamiento, cada fragmento recibe además una **copia degradada** al azar: canal telefónico (filtro de 300–3400 Hz), ruido de fondo con relación señal-ruido de 10 a 30 dB o saturación de micrófono barato. La aumentación se aplica por igual a todas las clases, para que "audio ruidoso" no se vuelva pista de clase. **No se usa cambio de tono**, porque alteraría justo la señal de la edad.

5.3. Representaciones de la voz

Cada fragmento se convierte en un vector numérico de longitud fija con tres extractores distintos, de lo más interpretable a lo más potente:

Tabla 3: Extractores de características.

Extractor	Dimensiones	Qué representa	Tiempo (ms)
Acústico clásico	118	Tono (frecuencia fundamental), formantes F1–F3, coeficientes cepstrales en escala mel y rasgos espectrales	16
ECAPA-TDNN [12]	192	"Huella vocal" de una red entrenada para reconocer hablantes (SpeechBrain [13], VoxCeleb)	29
WavLM-base-plus [14]	1 536	Representación autosupervisada aprendida de 94 000 horas de habla (Transformers)	89

La figura 3 confirma la hipótesis fisiológica en nuestros datos: los niños tienen un tono claramente más alto (mediana de 242 Hz). En cambio, los adolescentes y los adultos se superponen casi por completo (147 y 154 Hz), lo que anticipa la principal dificultad del problema.

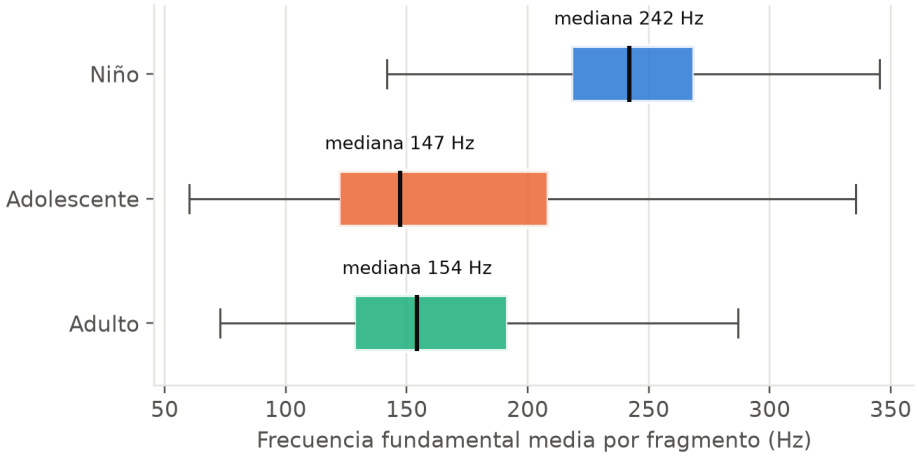


Figura 3: Tono fundamental medio por clase de edad, en todo el conjunto de datos.

5.4. Modelos y por qué los usamos

Se entrenaron seis modelos, cada uno formado por una representación y un clasificador. Los tres principales (A, B, C) cubren de lo más interpretable a lo más potente; los otros tres son variantes livianas que permiten separar qué aporta la representación y qué aporta el clasificador.

Tabla 4: Modelos comparados y justificación.

	Representación	**Clasificador**	**Por qué**
A	Acústica clásica	Potenciación del gradiente [19]	La fisiología explica la edad. Los árboles capturan umbrales no lineales ("tono alto y formantes altos ⇒ niño"), son interpretables y corren en cualquier computadora.
B	ECAPA-TDNN	Máquina de vectores de soporte [16]	ECAPA es el estado del arte en reconocimiento de hablante; su vector resume tamaño del tracto vocal, timbre y tono. Es compacto, y la máquina de vectores de soporte generaliza bien con pocos datos de menores gracias al margen máximo. Además, el mismo vector sirve para la diarización.
C	WavLM	Regresión logística	WavLM lidera el banco de pruebas SUPERB en tareas de hablante y paralingüística [15]. Un clasificador lineal sobre el modelo congelado evita el sobreajuste con pocos datos y permite entrenar en una computadora personal.
A2	Acústica clásica	Bosque aleatorio [17]	Línea base liviana sin redes neuronales; ¿aporta la potenciación frente a árboles independientes?
A3	Acústica clásica	Regresión logística	Piso de referencia: ¿basta un modelo lineal sobre rasgos fisiológicos?
B2	ECAPA-TDNN	Bosque aleatorio	Misma representación que B con otro clasificador.

5.5. Cómo funciona cada modelo

Cada modelo tiene dos piezas: un *extractor*, que convierte la voz en un vector de números, y un *clasificador*, que convierte ese vector en tres probabilidades.

Extractores.

- **Acústico clásico.** Mide la voz con fórmulas de procesamiento de señales, sin aprendizaje. El tono se estima buscando cada cuánto se repite la onda (algoritmo YIN). Los formantes, que son las resonancias del tracto vocal, se obtienen modelando la voz como un filtro (predicción lineal) y buscando sus picos. Los coeficientes cepstrales en escala mel resumen la forma del espectro tal como la percibe el oído. Cada medida se resume con su media, desviación, mediana y percentiles.
- **ECAPA-TDNN** [12]. Red neuronal convolucional que recorre el espectrograma a lo largo del tiempo. Sus bloques aprenden a resaltar los canales de frecuencia más útiles (atención por canal) y combinan información de varias capas. Al final, una capa de *agrupamiento estadístico con atención* pondera los instantes más informativos y produce un vector de 192 números por fragmento. Se entrenó para distinguir a miles de personas de VoxCeleb, así que el vector captura *cómo suena* una voz y no *qué dice*.
- **WavLM** [14]. Una red convolucional convierte la onda en una secuencia de vectores, uno cada 20 ms, y un Transformer de 12 capas los relaciona entre sí. Se entrenó sin etiquetas: se tapan partes del audio, a veces mezclado con otra voz o con ruido, y el modelo aprende a predecir lo que falta. Sus capas intermedias guardan información sobre el hablante y las finales sobre las palabras. Usamos el promedio de las capas 3 a 8, resumido con media y desviación en el tiempo, y no modificamos sus pesos.

Clasificadores.

- **Potenciación del gradiente (A).** Construye cientos de árboles de decisión poco profundos en secuencia; cada árbol nuevo corrige los errores que dejaron los anteriores. Agrupa los valores en intervalos (histogramas) para entrenar rápido.
- **Bosque aleatorio (A2, B2).** Entrena 300 árboles independientes, cada uno con una muestra distinta de los datos y un subconjunto al azar de las características, y promedia sus votos. La variedad entre árboles reduce el sobreajuste.
- **Máquina de vectores de soporte (B).** Proyecta los vectores a un espacio de muchas dimensiones mediante un núcleo gaussiano, donde busca la frontera que deja el mayor margen posible entre clases. Solo los ejemplos cercanos a la frontera (los vectores de soporte) la definen, por eso funciona bien con pocos datos. Para tres clases entrena un clasificador por cada par de clases.
- **Regresión logística (C, A3).** Asigna un peso a cada característica, suma y convierte el resultado en probabilidades con la función *softmax*. Es una frontera lineal: simple, rápida y difícil de sobreajustar.
- **Calibración sigmoide.** Después de entrenar, se ajusta una curva sigmoide sobre el conjunto de validación que convierte las salidas del clasificador en probabilidades fiables [18].

5.6. Independencia del idioma: sustento y matices

La propuesta supone que la edad se puede estimar por la voz sin importar el idioma. La evidencia apoya esa idea en lo esencial, con matices que conviene conocer.

Por qué la señal de edad no depende del idioma.

- **Es anatómica.** El tracto vocal crece con la edad: un estudio con resonancia magnética de 129 personas de 2 a 25 años midió ese crecimiento y lo relacionó con el descenso de los formantes [20]. Un análisis acústico de 436 niños de 5 a 17 años y 56 adultos mostró que el tono y los formantes bajan con la edad y alcanzan los valores adultos alrededor de los 15 años [21]. Ningún idioma cambia el largo del tracto vocal ni el tamaño de las cuerdas vocales.
- **La diferencia por edad es mucho mayor que la diferencia por idioma.** En nuestros datos, la mediana del tono pasa de 242 Hz en niños a 154 Hz en adultos: unos 7,8 semitonos. Entre idiomas, en cambio, el rango *fisiológico* de tono de hablantes de inglés y de mandarín es prácticamente igual, y al leer un texto solo difiere un poco el tono medio [22]. Entre inglés y alemán, las diferencias están sobre todo en cuánto *varía* el tono dentro de una frase, más que en su nivel [23].
- **Las personas también lo logran.** Oyentes de un idioma estiman con cierto acierto la edad de hablantes de otro idioma, aunque aciertan más con el propio [24], y el tono medio es una de las pistas que más usan [25].
- **El modelo desplegado se basa en un extractor multilingüe.** ECAPA-TDNN se entrenó con VoxCeleb, cuya segunda versión reúne a más de 6 000 personas de 145 nacionalidades que hablan muchos idiomas [26]. Su vector describe la voz, no el idioma.
- **El diseño no usa nada léxico.** No hay transcripción, palabras ni modelo de lenguaje; los rasgos se promedian sobre varios segundos, lo que diluye la entonación propia de cada frase.

Matices.

- El idioma sí cambia la *prosodia*: cuánto sube y baja el tono y la velocidad del habla [23, 22]. La velocidad también es una pista de edad [25], así que podría confundir al modelo en un idioma más rápido o más lento que el inglés.
- WavLM se preentrenó solo con audio en inglés [14]; es el extractor con más riesgo de depender del idioma.
- En aprendizaje de máquina, transferir la predicción de edad a idiomas nuevos sin datos de ellos todavía da resultados irregulares [27].
- Nuestro modelo se entrenó y evaluó solo con inglés.

Conclusión. La propuesta descansa en una señal anatómica que el idioma no modifica y cuya magnitud supera con mucho las diferencias entre idiomas, por lo que es razonable esperar que se transfiera. Aun así, es una hipótesis por validar: el siguiente paso es evaluar el mismo modelo con voces en español (por ejemplo, Common Voice en español) y comparar sus métricas con las obtenidas en inglés.

5.7. Protocolo de entrenamiento

Todos los modelos siguen el mismo protocolo, para que la comparación sea justa:

- **Pesos de clase balanceados**, porque hay menos adolescentes.
- **Hiperparámetros** elegidos con una búsqueda en cuadrícula sobre el conjunto de validación, usando F1-macro.
- **Calibración sigmoide** [18] sobre validación. El riesgo multiplica probabilidades, así que estas deben ser fiables: un 0,9 debe acertar cerca del 90 % de las veces.
- **Evaluación una sola vez** en el conjunto de prueba, con hablantes que el modelo nunca vio.
- **Selección** del ganador por F1-macro en prueba; en caso de empate, gana el de mayor sensibilidad para niños, porque en una alerta el error más grave es no detectar al menor.

5.8. Puntaje de riesgo

El puntaje responde a una sola pregunta: *¿qué tan seguros estamos de que en este audio hablan una persona menor de edad y una persona adulta distintas?* Para cada par de hablantes distintos i (posible menor) y j (posible adulto):

$$r(i,j) = P_i(\text{niño})\, P_j(\text{adulto}) \cdot 0{,}90 \;+\; P_i(\text{adolescente})\, P_j(\text{adulto}) \cdot 0{,}60 \tag{1}$$

$$R = \text{máx}\left(0{,}05,\ \max_{i \neq j} r(i,j)\right) \tag{2}$$

Por qué cada elemento.

- **Probabilidad por hablante, promediada por duración.** Cada hablante se evalúa en trozos de hasta 6 s y sus probabilidades se promedian ponderando por la duración de cada trozo: un trozo largo tiene más voz y es más fiable que uno corto.
- **Pares de hablantes distintos ($i \neq j$).** La situación de interés requiere dos personas. Por eso primero se separan los hablantes y una misma voz nunca puede ser a la vez "el menor" y "el adulto".
- **Producto $P_i(\cdot)\, P_j(\textbf{adulto})$.** Si las estimaciones de dos hablantes distintos son independientes, el producto es la probabilidad de que *ambas* cosas sean ciertas a la vez: i es menor y j es adulto. Así, la duda sobre cualquiera de los dos baja el riesgo; un mínimo o un promedio ignorarían parte de esa incertidumbre.

- **Suma de los dos términos.** “Niño” y “adolescente” son excluyentes para un mismo hablante, así que sumar sus términos da el *valor esperado* del peso del par. Un hablante que el modelo duda entre niño y adolescente aporta por ambas vías, sin contarse dos veces.
- **Solo pares con un adulto.** El patrón que se busca es un adulto que interactúa con un menor. Las conversaciones entre menores, o solo entre adultos, no lo cumplen y quedan en el piso.
- **Máximo sobre los pares.** Basta una pareja menor–adulto para que valga la pena revisar. Promediar diluiría la alerta en llamadas con muchos participantes; por ejemplo, un menor con cinco adultos daría un riesgo bajo.
- **Peso de 0,90 para niño + adulto.** Es el valor máximo posible y es deliberadamente menor que 1: aun con certeza total sobre las edades, la combinación no prueba un abuso. Además, la edad estimada por la voz nunca es segura.
- **Peso de 0,60 para adolescente + adulto.** *No* significa que el riesgo para los adolescentes sea menor: la edad promedio de las víctimas en reportes de incitación en línea es de 15 años [28]. El peso es menor por la *fiabilidad de la estimación*. La voz adolescente alcanza valores adultos hacia los 15 años [21] y se superpone con la adulta (figura 3); nuestro modelo solo detecta el 60 % de los adolescentes; la etiqueta de entrenamiento incluye a personas de 18 y 19 años; y las interacciones legítimas entre adolescentes y adultos (escuela, trabajo, deporte) son muy frecuentes. El peso evita inundar a los revisores de falsas alertas, a costa de detectar menos casos de adolescentes. Es el parámetro que más conviene recalibrar con datos reales.
- **Piso de 0,05.** El sistema nunca afirma “riesgo cero”: la diarización o la estimación de edad pueden fallar.
- **Umbral alto de 0,60.** Es exactamente el puntaje de un adolescente y un adulto con certeza total, y el de un niño y un adulto con un 67 % de certeza conjunta (0,60/0,90). Cualquiera de esas dos situaciones amerita revisión prioritaria.
- **Umbral medio de 0,30.** Es la mitad del umbral alto: señales parciales (por ejemplo, un probable menor junto a una voz de edad dudosa) que conviene revisar sin urgencia.
- **Probabilidades calibradas.** Todo lo anterior solo tiene sentido si un 0,9 significa de verdad un 90 % de aciertos. Por eso cada modelo se calibra antes de usarse.

Tabla 5: Ejemplos del cálculo del riesgo.

Situación	**Hablante** i	**Hablante** j	**Riesgo**	**Nivel**
Niño y adulto, ambos claros	niño 0,95	adulto 0,90	$0{,}95 \cdot 0{,}90 \cdot 0{,}90 = 0{,}77$	alto
Adolescente y adulto, ambos seguros	adolescente 1,00	adulto 1,00	0,60	alto
Probable niño, adulto dudoso	niño 0,80	adulto 0,50	$0{,}80 \cdot 0{,}50 \cdot 0{,}90 = 0{,}36$	medio
Hablante entre niño y adolescente	niño 0,5, adol. 0,4	adulto 0,90	$0{,}41 + 0{,}22 = 0{,}62$	alto
Dos adultos	adulto 0,95	adulto 0,95	piso: 0,05	bajo

Supuestos y límites del puntaje. Supone que los errores de los dos hablantes son independientes, lo que no se cumple del todo si comparten micrófono o ruido. Los pesos y umbrales son parámetros de diseño razonados, no aprendidos: deben ajustarse con conversaciones reales anotadas antes de cualquier uso.

6. Resultados

6.1. Comparativa de modelos

El modelo B (ECAPA-TDNN + máquina de vectores de soporte) obtuvo el mejor F1-macro y la mejor sensibilidad para adolescentes, y es el que se usa en el sistema (tabla 6 y figura 4). La evaluación usa 3 724 fragmentos de hablantes nunca vistos.

Tabla 6: Resultados en el conjunto de prueba (por fragmento). En negritas, el mejor valor.

Modelo	F1-macro	Exact. bal.	Sens. niño	Sens. adol.	Sens. adulto	AUC
B ECAPA + SVM	**0,817**	**0,814**	0,987	**0,604**	0,852	**0,943**
C WavLM + reg. log.	0,786	0,778	**1,000**	0,427	0,906	0,940
B2 ECAPA + bosque	0,776	0,768	0,965	0,430	0,910	0,941
A2 Acústico + bosque	0,730	0,728	0,994	0,308	0,884	0,900
A Acústico + pot. grad.	0,708	0,710	0,997	0,261	0,872	0,870
A3 Acústico + reg. log.	0,598	0,658	0,999	0,010	**0,965**	0,872

Sens. = sensibilidad (proporción detectada de cada clase). AUC = área bajo la curva para separar menores de adultos.

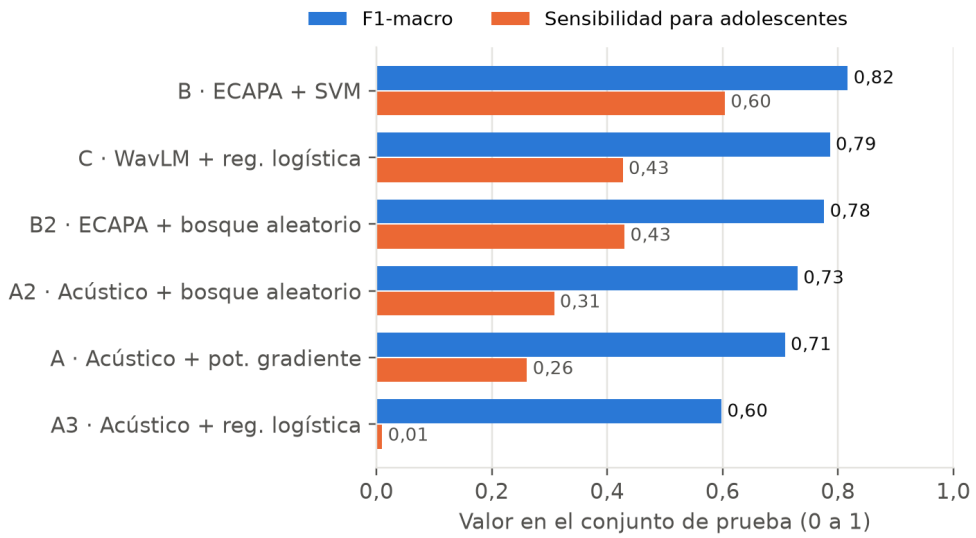


Figura 4: F1-macro y sensibilidad para adolescentes de cada modelo.

Lecturas principales.

- **La representación pesa más que el clasificador.** Con rasgos acústicos el mejor modelo llega a 0,730; con ECAPA, incluso un bosque aleatorio sube a 0,776.
- **Con ECAPA, la máquina de vectores de soporte supera al bosque aleatorio** (0,817 frente a 0,776), y la diferencia está en los adolescentes (0,604 frente a 0,430).
- **Un modelo lineal sobre rasgos acústicos casi no detecta adolescentes** (0,010): como muestra la figura 3, su tono es casi igual al de los adultos, y la frontera entre ambas clases no es lineal.
- **El error típico del modelo B es confundir adolescentes con adultos**; casi nunca confunde a un niño con un adulto.
- **La sensibilidad para niños (0,97–1,00) debe leerse con cautela**: todos los niños provienen de habla sintetizada (sección 6.3).

6.2. Eficiencia

El costo de inferencia lo pone casi por completo el extractor, no el clasificador:

Tabla 7: Tiempo de inferencia por fragmento en CPU y tamaño.

Modelo	F1-macro	ms/fragmento	Clasificador (MB)	Red (MB)
B ECAPA + SVM	0,817	29	15,9	83
C WavLM + reg. log.	0,786	89	0,1	378
A2 Acústico + bosque	0,730	16	35,9	0

El modelo acústico con bosque aleatorio (A2) es la mejor opción sin redes neuronales y tarda la mitad que B. Pero el sistema necesita ECAPA de todos modos para la diarización, así que cambiar a A2 casi no ahorraría recursos y costaría 0,09 de F1-macro y la mitad de la sensibilidad para adolescentes.

6.3. Auditoría de sesgo por canal

El mayor riesgo metodológico es que **clase y fuente coinciden**: todos los niños vienen de habla sintetizada y limpia, y todos los demás de grabaciones caseras. El modelo podría aprender "qué tipo de audio es" en lugar de "qué edad tiene". Se hicieron tres comprobaciones:

- **Diferencias de canal:** los audios infantiles eran unos 13 dB más bajos y con distinto espectro. La diferencia de volumen se elimina con la normalización; la de espectro, no.
- **Predictibilidad de la fuente:** un clasificador simple adivina la fuente en el 98,8 % de los casos con los vectores ECAPA (57,9 % por azar). Con estos datos es inevitable, porque predecir la fuente equivale a predecir "niño".
- **Robustez al canal:** se degradó el audio de prueba con ruido y canal telefónico. Si el modelo usara "audio limpio = niño", su sensibilidad para niños se desplomaría.

Tabla 8: Modelo B con audio de prueba original y degradado.

Audio	F1-macro	Sens. niño	Sens. adol.	Sens. adulto	AUC
Original	0,817	0,987	0,604	0,852	0,943
Degradado	0,813	0,979	0,567	0,876	0,944

Conclusión: el modelo no depende de que el audio sea limpio, pero todavía podría apoyarse en que la voz infantil es sintetizada. Para descartarlo hace falta un corpus con niños y adultos reales grabados en las mismas condiciones.

6.4. Conversaciones simuladas

Para probar el sistema completo se armaron conversaciones alternando turnos de hablantes de prueba, 20 por escenario:

Tabla 9: Resultados del flujo completo con conversaciones simuladas.

Escenario	Riesgo medio	Alertas altas	Hablantes detectados (reales)
Niño + adulto	0,585	80 %	3,3 (2)
Adolescente + adulto	0,231	0 %	2,1 (2)
Adulto + adulto	0,183	0 %	2,4 (2)
Niño + niño	0,084	0 %	3,9 (2)
Adulto solo	0,068	0 %	1,2 (1)

- **Las conversaciones entre niño y adulto generan alerta alta en el 80 % de los casos**, y los escenarios sin menores se quedan en riesgo bajo.
- **La diarización cuenta hablantes de más cuando hay niños**, porque cada fragmento sintetizado suena como una voz distinta. Eso reparte al niño entre varios hablantes falsos y baja el riesgo medio. Si se conoce el número de participantes, indicarlo corrige el problema: con dos hablantes indicados, una conversación de prueba niño–adulto obtuvo 71 % (alto), con el niño identificado al 87 % y el adulto al 84 %.
- **"Adolescente + adulto" casi nunca alerta**, consecuencia directa de la baja sensibilidad para adolescentes.

7. El sistema en funcionamiento

El modelo ganador se sirve mediante una API web en un contenedor Docker que funciona sin conexión a internet y solo con CPU. Recibe un archivo de audio de hasta 10 minutos y devuelve:

- el puntaje de riesgo (0 a 1), su porcentaje y su nivel (bajo, medio, alto);
- el número de hablantes detectados y, para cada uno, su duración, sus intervalos de habla y sus probabilidades de edad;
- un **aviso obligatorio**, en todas las respuestas, de que el resultado es una alerta y no un veredicto.

El audio se procesa en un archivo temporal que se borra al terminar: el servicio no conserva grabaciones ni transcripciones. Tras la carga inicial del modelo, analizar una conversación de 10 s tomó menos de 0,2 s.

8. Pruebas realizadas

Tabla 10: Resumen de pruebas.

Prueba	**Qué verifica**	**Resultado**
Pruebas unitarias (15 casos)	Fronteras de edad; riesgo de 90 % para niño + adulto y de 60 % para adolescente + adulto; piso sin pareja menor–adulto; escalado con la incertidumbre	15/15 correctas
Ausencia de fuga de hablantes	Ningún hablante en dos particiones	Verificada
Calidad de datos	Eliminación de fragmentos mudos y verificación de etiquetas	13 mudos eliminados
Entrenamiento completo	Todo el proceso de principio a fin	Sin errores
Robustez al canal	Rendimiento con audio degradado	F1 de 0,817 a 0,813
Conversaciones simuladas	Flujo completo en 5 escenarios	Ver sección de resultados
API local y en contenedor	Respuestas idénticas en ambos entornos, aviso presente	Correcta

9. Limitaciones y trabajo futuro

Tabla 11: Limitaciones conocidas y mejoras propuestas.

Limitación	Efecto	Mejora
Todos los niños provienen de habla sintetizada	El rendimiento con niños puede estar inflado	Corpus con niños y adultos reales en el mismo canal (speechocean762, MyST, CSLU Kids)
Pocos adolescentes (25 grupos)	Sensibilidad de 0,60; casi no hay alertas adolescente–adulto	Más datos de adolescentes con edad exacta
"Teens" en Common Voice incluye 18 y 19 años	Etiquetas ruidosas	Corpus con edad exacta
Solo inglés	Rendimiento desconocido en español	Añadir voces en español
Diarización ligera	Cuenta hablantes de más con voces infantiles	Diarización neuronal (pyannote, NeMo)
Evaluación con conversaciones simuladas	Resultados optimistas	Validación con conversaciones reales anotadas, con consentimiento

Con más datos de menores, el siguiente paso natural es ajustar finamente WavLM en lugar de usarlo congelado, y calibrar los umbrales de riesgo con conversaciones reales.

10. Consideraciones éticas

- **Falsos positivos esperados.** La mayoría de las alertas corresponderán a conversaciones legítimas con familiares, docentes o médicos. El puntaje sirve para priorizar, no para concluir.
- **Sin decisiones automáticas.** Ninguna acción con consecuencias (bloqueos, denuncias, sanciones) debe tomarse solo con el puntaje; toda alerta requiere revisión humana especializada.
- **Lenguaje prudente.** El sistema habla de "riesgo" y "alerta", nunca de "grooming detectado".
- **Datos sensibles.** Las voces de menores son datos personales sensibles. Se usaron solo corpus públicos para investigación, no se versionan los audios y el servicio no guarda grabaciones.
- **Despliegue real.** Requeriría base legal, aviso o consentimiento adecuado y una evaluación de impacto en protección de datos.

11. Conclusiones

- Es posible estimar, solo con la voz y sin analizar el contenido, si en una conversación hablan un menor y un adulto: el mejor modelo alcanza un F1-macro de 0,817 y separa menores de adultos con un AUC de 0,943.
- Los vectores de hablante preentrenados (ECAPA-TDNN) superan a los rasgos acústicos clásicos y a una representación autosupervisada más grande (WavLM), con un costo de 29 ms por fragmento.
- Distinguir niños de adultos es relativamente fácil; distinguir adolescentes de adultos es el reto abierto, porque sus voces se superponen.

- El diseño protege la privacidad por construcción: no transcribe, no guarda audio y solo produce probabilidades de edad.
- Antes de cualquier uso real, el sistema necesita datos de niños reales grabados en las mismas condiciones que los adultos, y validación con conversaciones reales.

Referencias

[1] H. Whittle, C. Hamilton-Giachritsis, A. Beech y G. Collings. "A review of online grooming: Characteristics and concerns". *Aggression and Violent Behavior*, 18(1):62–70, 2013.

[2] National Center for Missing & Exploited Children. "NCMEC Releases New Data: 2024 in Numbers", 2025. https://www.missingkids.org/blog/2025/ncmec-releases-new-data-2024-in-numbers

[3] Thorn. "What the 2024 NCMEC CyberTipline Report Says About Child Safety", 2025. https://www.thorn.org/blog/what-the-2024-ncmec-cybertipline-report-says-about-child-safety/

[4] NSPCC. "Data shows how criminals are using private messaging platforms to manipulate and groom children", noviembre de 2025. https://www.nspcc.org.uk/about-us/news-opinion/2025/data-shows-how-criminals-are-using-private-messaging-platforms-to-manipulate-and-groom-children/

[5] WeProtect Global Alliance. *Global Threat Assessment 2023*. https://www.weprotect.org/global-threat-assessment-23/

[6] INEGI. *Módulo sobre Ciberacoso (MOCIBA) 2024*, comunicado de prensa 76/25, 17 de julio de 2025. https://www.inegi.org.mx/programas/mociba/2024/

[7] EDPB y EDPS. *Joint Opinion 4/2022 on the Proposal for a Regulation laying down rules to prevent and combat child sexual abuse*, 28 de julio de 2022. https://edps.europa.eu/data-protection/our-work/publications/edps-edpb-joint-opinions/2022-07-28-joint-opinion-42022-regulation-european-parliament-and-council-rules-prevent-and-combat-child-sexual-abuse_en

[8] G. Inches y F. Crestani. "Overview of the International Sexual Predator Identification Competition at PAN-2012". *CLEF 2012 Evaluation Labs and Workshop*, 2012.

[9] P. Schneider, R. V. Dubé y D. Hayward. *The Edmonton Narrative Norms Instrument*. University of Alberta, 2005.

[10] jsun39. *enni-child-speech-synthesis* (conjunto de datos). Hugging Face. https://huggingface.co/datasets/jsun39/enni-child-speech-synthesis

[11] R. Ardila et al. "Common Voice: A Massively-Multilingual Speech Corpus". *Proceedings of LREC*, 2020.

[12] B. Desplanques, J. Thienpondt y K. Demuynck. "ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification". *Interspeech*, 2020.

[13] M. Ravanelli et al. "SpeechBrain: A General-Purpose Speech Toolkit". arXiv:2106.04624, 2021.

[14] S. Chen et al. "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing". *IEEE Journal of Selected Topics in Signal Processing*, 16(6), 2022.

[15] S. Yang et al. "SUPERB: Speech processing Universal PERformance Benchmark". *Interspeech*, 2021.

[16] C. Cortes y V. Vapnik. "Support-vector networks". *Machine Learning*, 20:273–297, 1995.

[17] L. Breiman. "Random Forests". *Machine Learning*, 45:5–32, 2001.

[18] J. Platt. "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods". *Advances in Large Margin Classifiers*, 1999.

[19] F. Pedregosa et al. “Scikit-learn: Machine Learning in Python”. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[20] W. T. Fitch y J. Giedd. “Morphology and development of the human vocal tract: A study using magnetic resonance imaging”. *Journal of the Acoustical Society of America*, 106(3):1511–1522, 1999.

[21] S. Lee, A. Potamianos y S. Narayanan. “Acoustics of children’s speech: Developmental changes of temporal and spectral parameters”. *Journal of the Acoustical Society of America*, 105(3):1455–1468, 1999.

[22] P. Keating y G. Kuo. “Comparison of speaking fundamental frequency in English and Mandarin”. *Journal of the Acoustical Society of America*, 132(2):1050–1060, 2012.

[23] I. Mennen, F. Schaeffler y G. Docherty. “Cross-language differences in fundamental frequency range: A comparison of English and German”. *Journal of the Acoustical Society of America*, 131(3):2249–2260, 2012.

[24] K. Gnevsheva y D. Bürkle. “Age estimation in foreign-accented speech by native and non-native speakers”. *Language and Speech*, 2020. `https://doi.org/10.1177/0023830919827621`

[25] Jiao et al. “Age estimation in foreign-accented speech by non-native speakers of English”. *Speech Communication*, 106:118–126, 2019.

[26] J. S. Chung, A. Nagrani y A. Zisserman. “VoxCeleb2: Deep Speaker Recognition”. *Interspeech*, 2018.

[27] S. Shu, S. S. Mohammadi Ziabari y A. M. M. Alsahag. “Cross-Language Speaker Attribute Prediction Using MIL and RL”. arXiv:2601.04257, 2026.

[28] National Center for Missing & Exploited Children. *The Online Enticement of Children: An In-Depth Analysis of CyberTipline Reports*, 2017. `https://www.missingkids.org/content/dam/missingkids/pdfs/ncmec-analysis/Online%20Enticement%20Exe%20Summary.pdf`